[redacted] · [redacted] · IA GÉNÉRATIVE VISUELLE

Reconstruire, générer et contrôler

TP2 — Auto-encodeurs, VAE, CVAE et PixelCNN

Amjad AAYD et [redacted]
20 octobre 2026

Preuve	Contenu
Apprentissage	6 modèles réellement entraînés sur GPU
Données	FashionMNIST et MNIST officiels
Analyse	12 questions de réflexion traitées
Livrables	Notebook exécuté, code commenté, figures, poids
Exécution	8 cellules de code sans erreur

Le code explique chaque manipulation avant son exécution. Les images de ce rapport sont les sorties effectives des modèles, sans retouche ni remplacement par des images illustratives.

01 / PROTOCOLE

Comment le travail a été réalisé

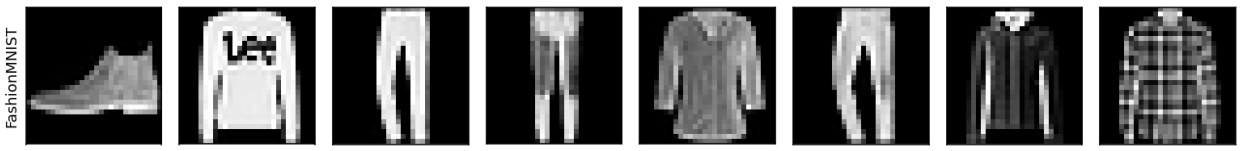
Le PDF est suivi dans l'ordre : AEs, VAE, CVAE, PixelCNN. FashionMNIST contient des vêtements ; MNIST contient des chiffres. Les images originales de 28 × 28 pixels sont conservées.

Normalisation : division par 255 pour obtenir des valeurs dans [0,1]. Pour PixelCNN, les cibles sont reconverties en entiers 0–255. Les étiquettes servent à conditionner le CVAE et à colorer t-SNE ; elles ne supervisent pas les autres générateurs.

Modèles	Apprentissage	Époques
AE dense / AE conv. / DAE	60 000 vêtements chacun	10 chacun
VAE	60 000 vêtements	12
CVAE	60 000 chiffres	24
PixelCNN	12 000 vêtements, tirage graine 42	10

Les jeux test officiels contiennent 10 000 images chacun. Le sous-ensemble PixelCNN limite le coût de calcul et est explicitement déclaré ; les 60 000 images ne sont pas revendiquées pour ce modèle. $\beta = 1$; l'extension optionnelle β-VAE n'est pas réalisée.

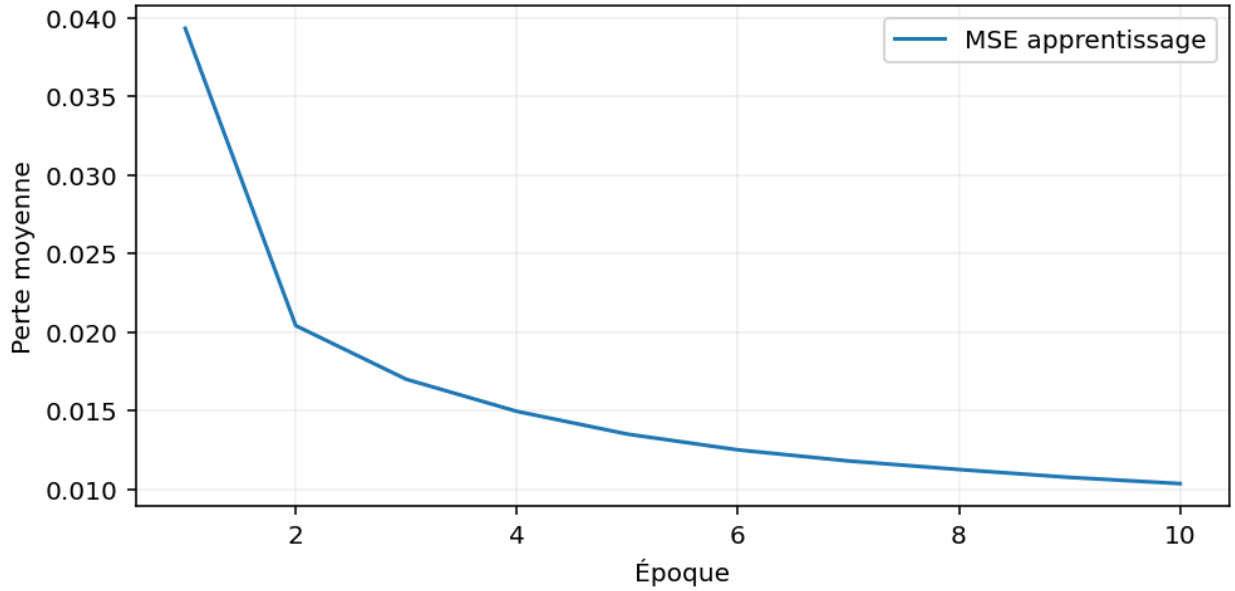
Matériel : GPU CUDA. PyTorch 2.12.0.dev20260408+cu128. Durée totale mesurée : 3.0 minutes. Les graines sont fixées, mais CUDA peut produire de petites variations entre exécutions.

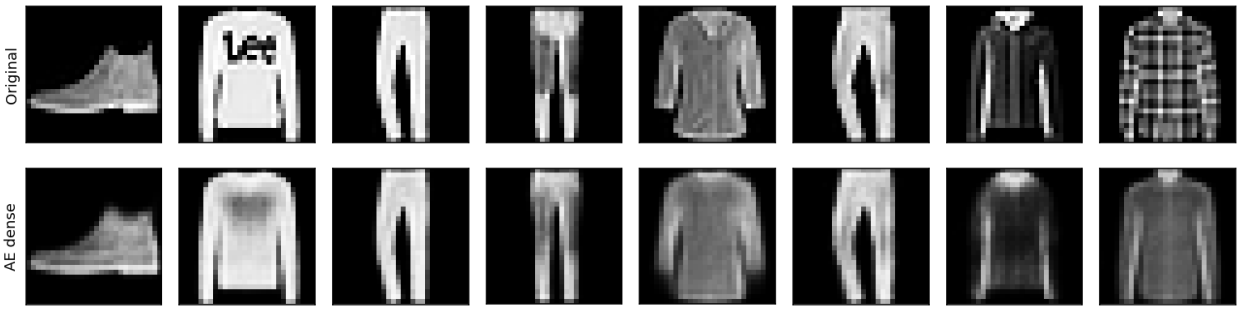


02 / AE DENSE

Compresser 784 pixels en 128 valeurs

Encodeur demandé : 784 → 1024 → 256 → 128. Décodeur symétrique avec sigmoïde finale. La MSE mesure l'écart carré moyen par pixel. La cible est l'image originale : aucune annotation manuelle n'est nécessaire.



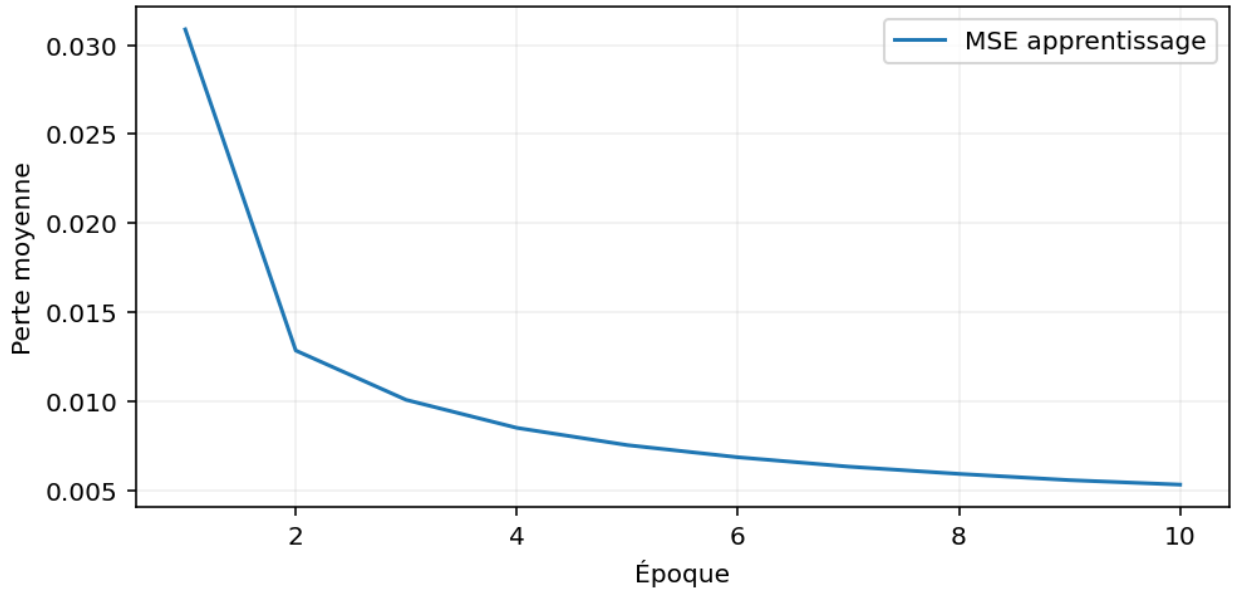


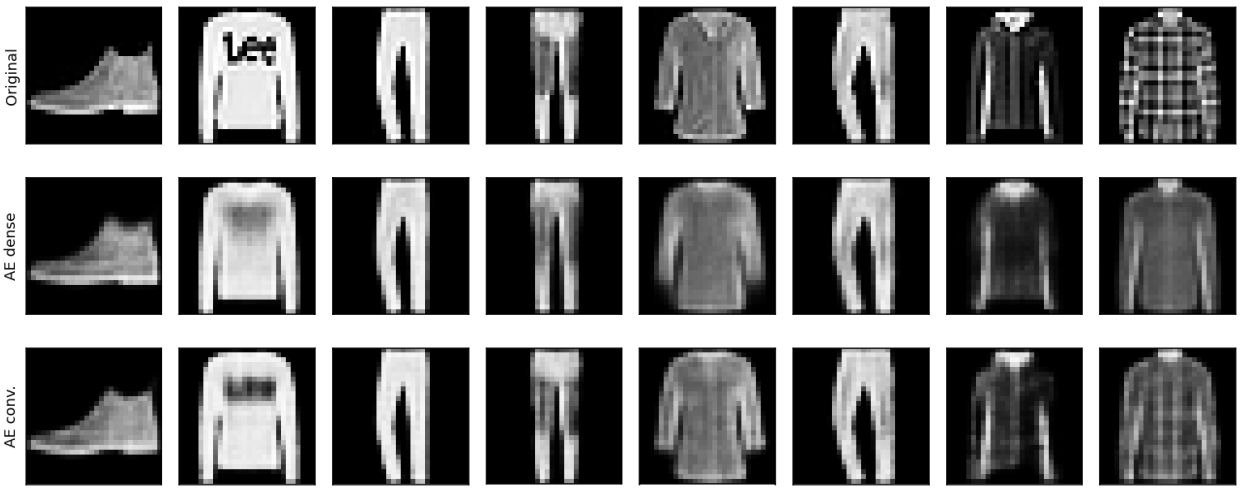
MSE test : 0.010391. Cette mesure porte sur des images absentes de l'apprentissage. Une faible MSE ne garantit pas à elle seule une image visuellement nette.

03 / AE CONVOLUTIONNEL

Exploiter les voisinages de pixels

Deux convolutions de stride 2 réduisent 28 → 14 → 7. Une couche linéaire produit le code de 128 valeurs. Deux convolutions transposées reconstruisent les dimensions initiales. Les filtres partagés exploitent la structure spatiale.



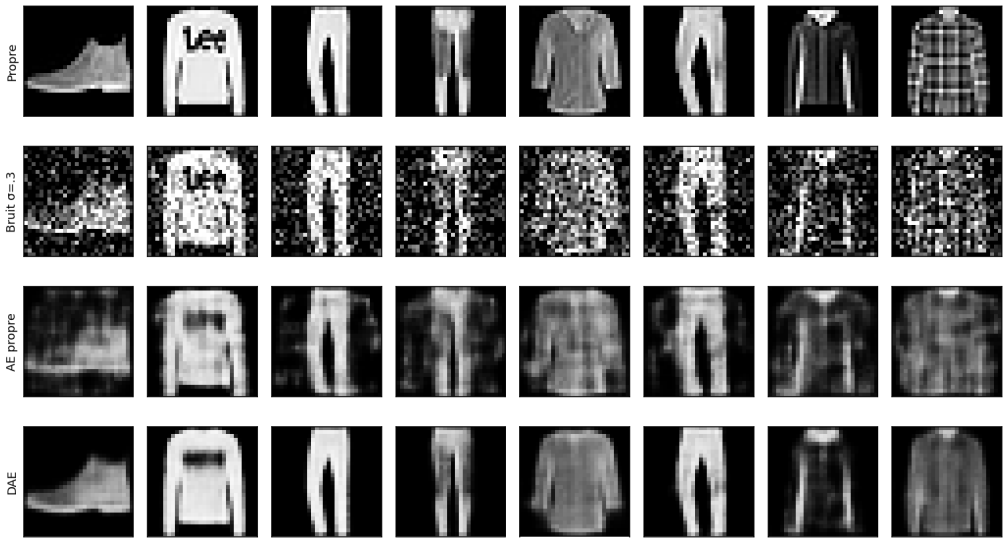


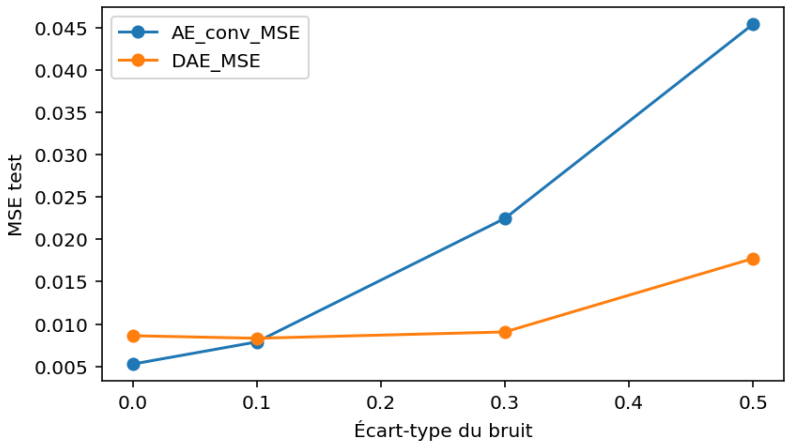
MSE test dense : 0.010391 ; convolutionnel : 0.005265. La comparaison visuelle utilise exactement les mêmes images. Ce résultat décrit ces architectures et ce budget d'entraînement, pas une supériorité universelle.

04 / DÉBRUITAGE

Reconstruire une cible propre depuis une entrée perturbée

On ajoute un bruit gaussien puis tronque dans [0,1]. Le modèle convolutionnel propre est comparé à un DAE entraîné avec σ = 0,3. Pour le DAE, la cible reste propre pendant tout l'apprentissage.



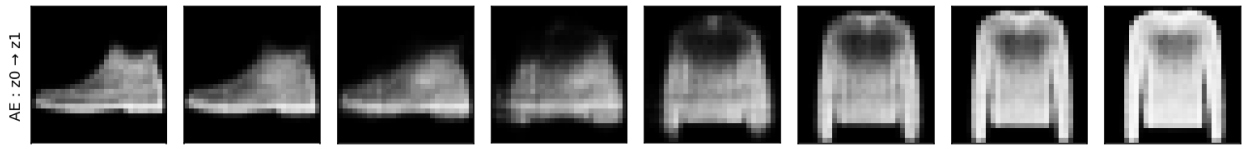


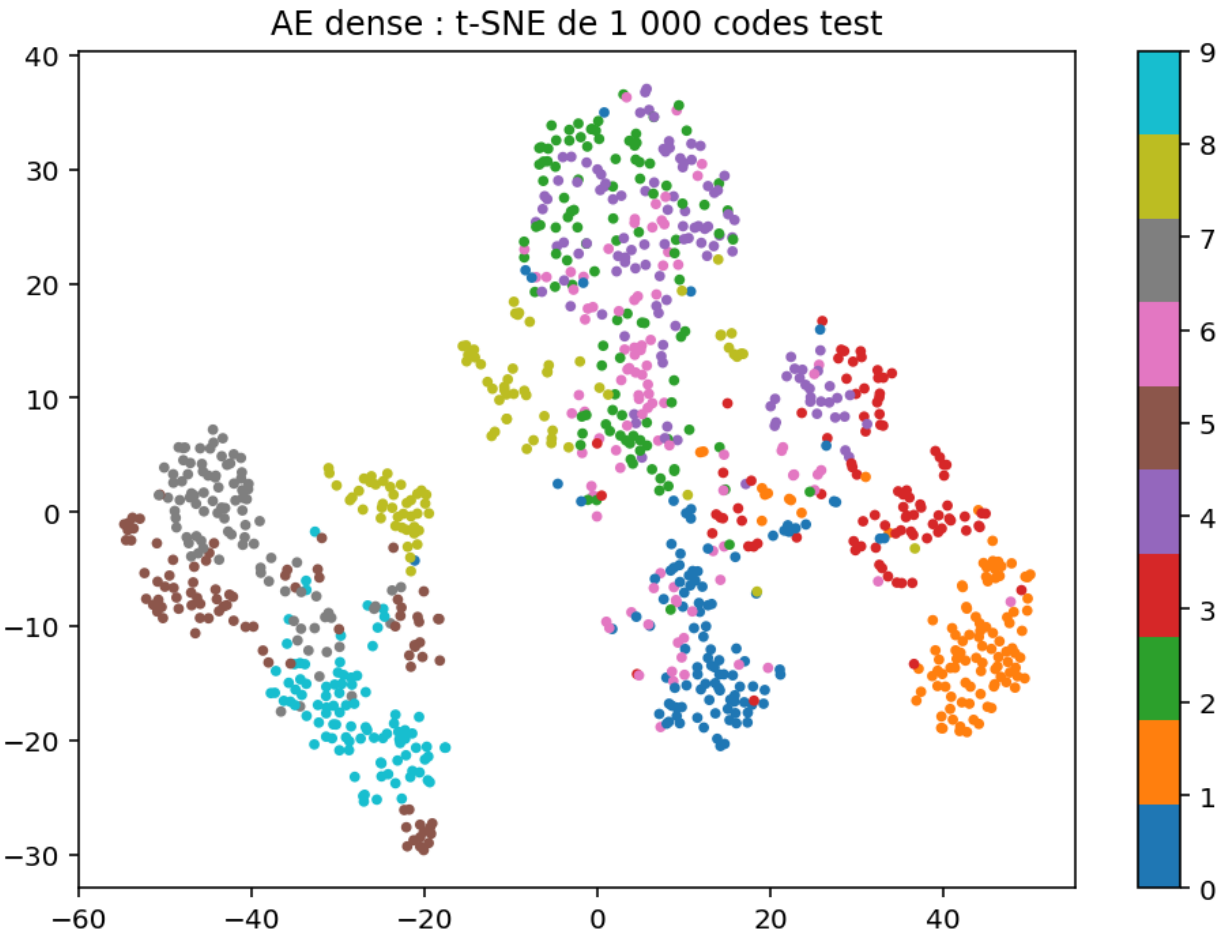
Bruit σ	MSE AE conv.	MSE DAE
0	0.005265	0.008617
0.1	0.007883	0.008314
0.3	0.022464	0.009063
0.5	0.045393	0.017737

Le bruit détruit progressivement de l'information. Apprendre à débruiter ne permet pas de retrouver avec certitude les détails qui ont disparu.

05 / ESPACE LATENT

Se déplacer entre les codes



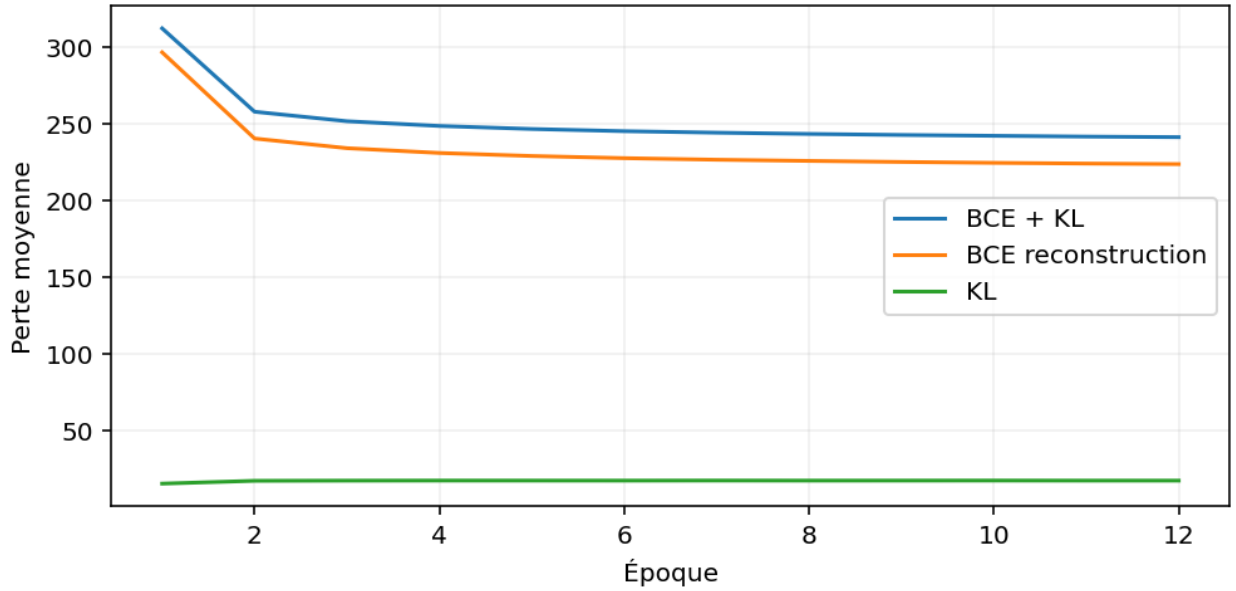


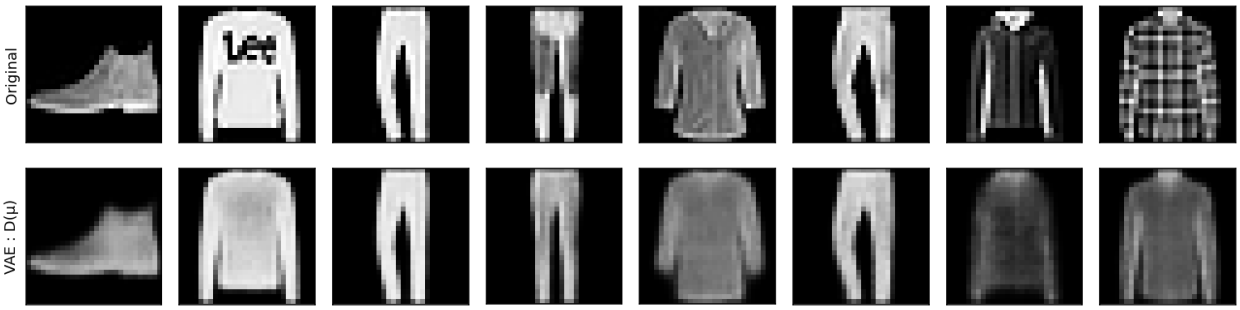
L’interpolation mélange les codes de deux images, puis les décode. L’AE ne contraint pas la distribution latente : une trajectoire peut traverser des régions peu plausibles. t-SNE montre seulement 1 000 codes test ; la projection déforme certaines distances et ne prouve pas une séparation parfaite des classes.

06 / VAE

Ajouter une distribution et une régularisation

L'encodeur produit μ et $\log \sigma^2$. La reparamétrisation $z = \mu + \sigma \times \varepsilon$ conserve un chemin différentiable. La perte BCE + KL est une somme par image moyennée sur le lot : les deux termes ont donc une échelle cohérente.

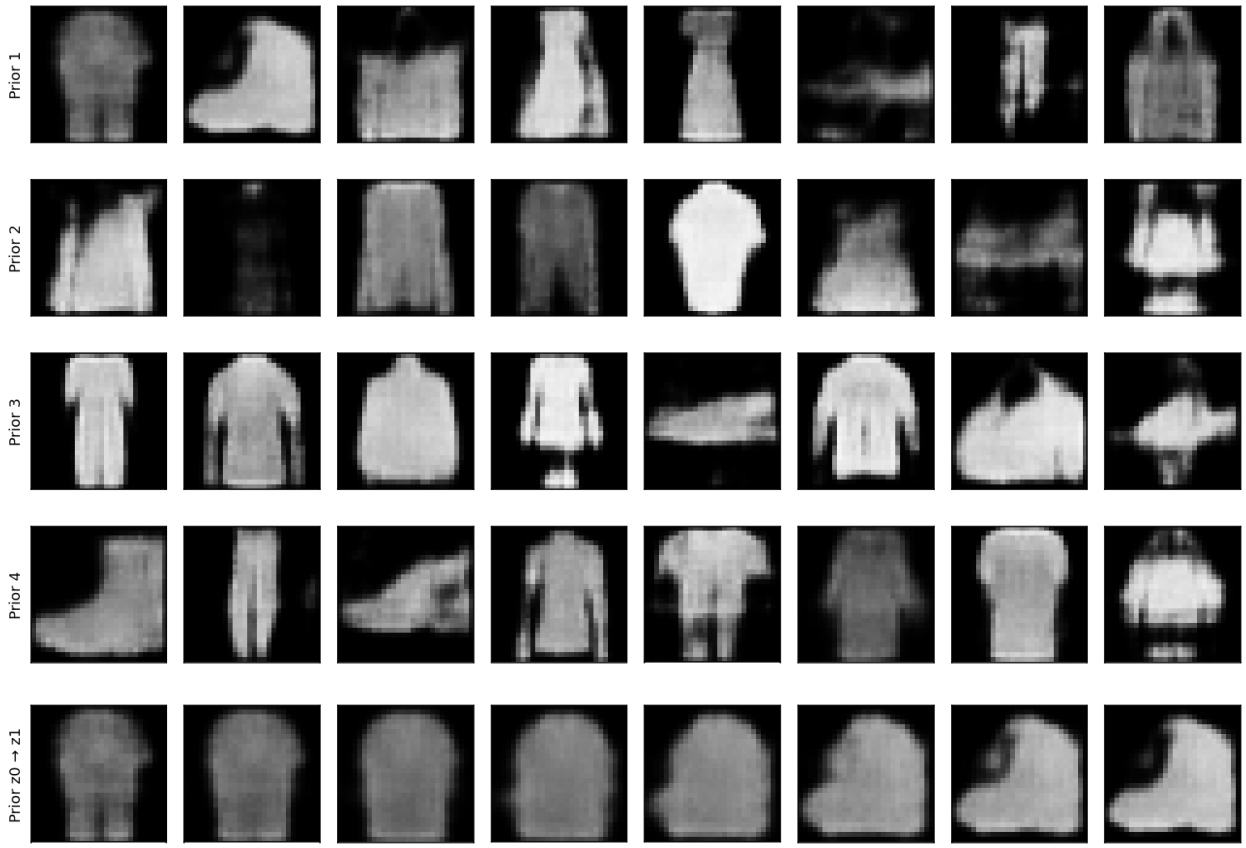


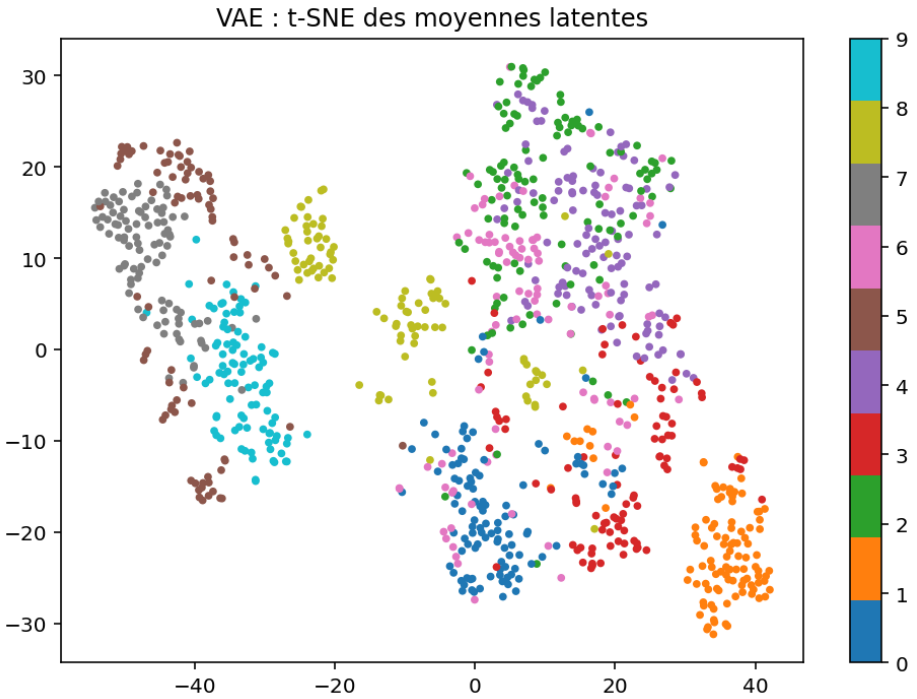


La reconstruction affichée utilise D(μ), plus stable qu'un tirage aléatoire. La KL rapproche les distributions encodées du prior N(0,I), au prix possible d'une perte de détails.

07 / GÉNÉRATION VAE

Tirer un code inédit depuis N(0,I)



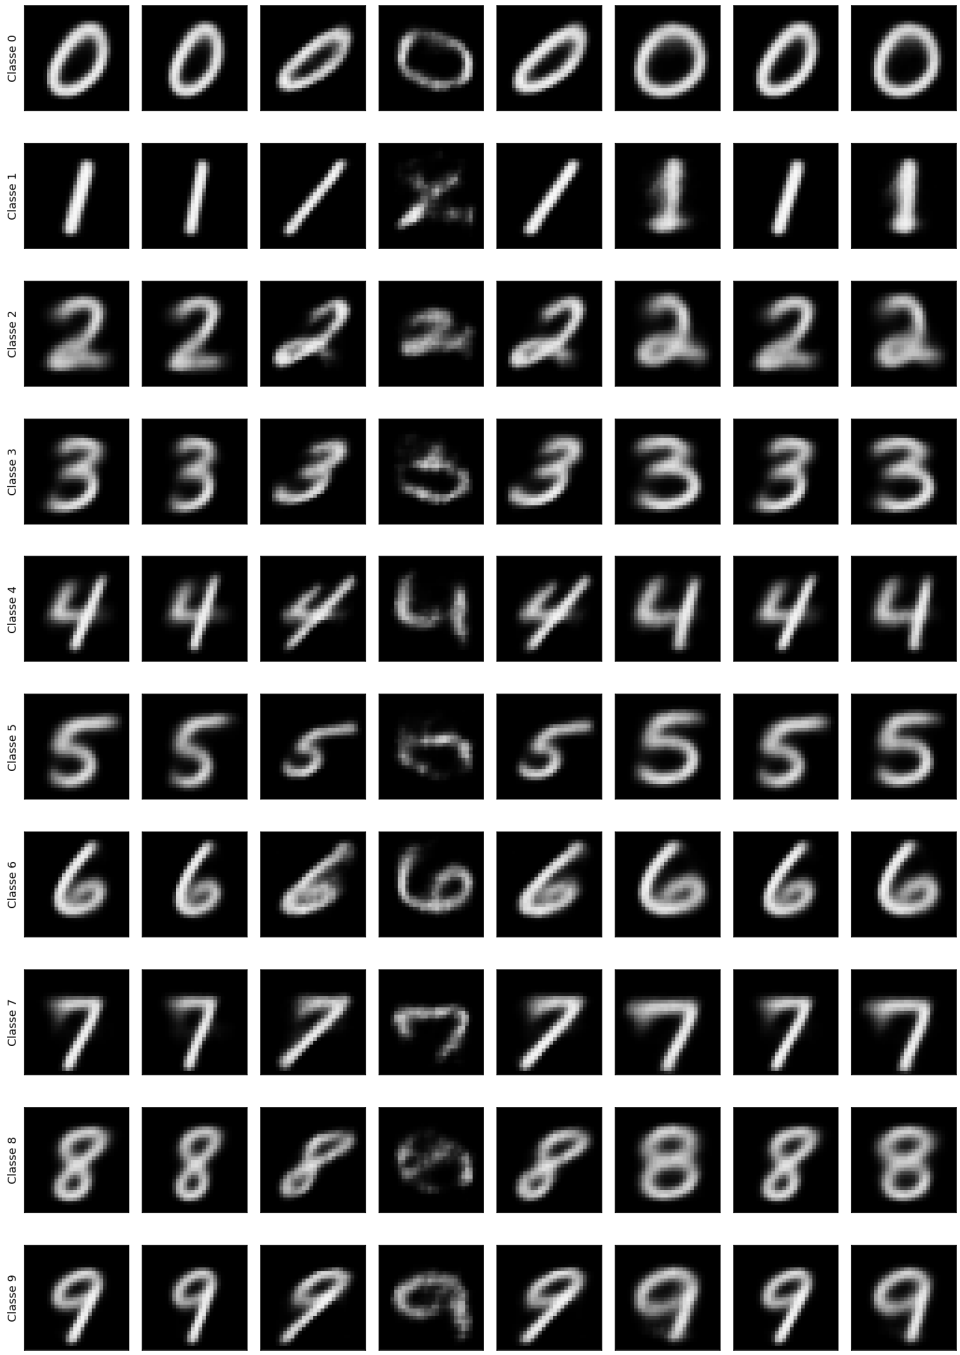


Les images générées ne sont pas les reconstructions d'images test. Elles proviennent de nouveaux tirages latents. La régularisation rend ces tirages plus exploitables ; elle ne garantit ni netteté ni absence de défauts.

08 / CVAE

Choisir la classe du chiffre généré

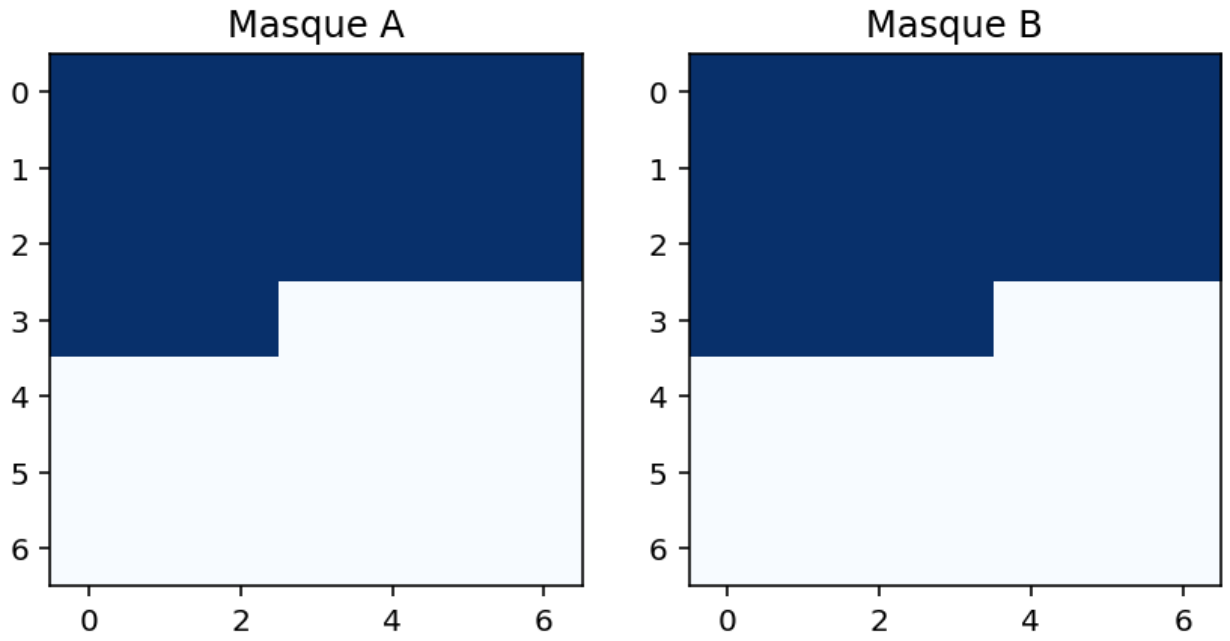
MNIST remplace FashionMNIST. Le vecteur one-hot y de taille 10 est concaténé à la représentation encodée et au code fourni au décodeur. Chaque colonne réutilise le même z ; chaque ligne change uniquement y. Un essai initial à 16 dimensions latentes ignorait parfois la classe. Le modèle final utilise 2 dimensions et 24 époques : la grille permet de vérifier le contrôle obtenu et les ambiguïtés restantes.

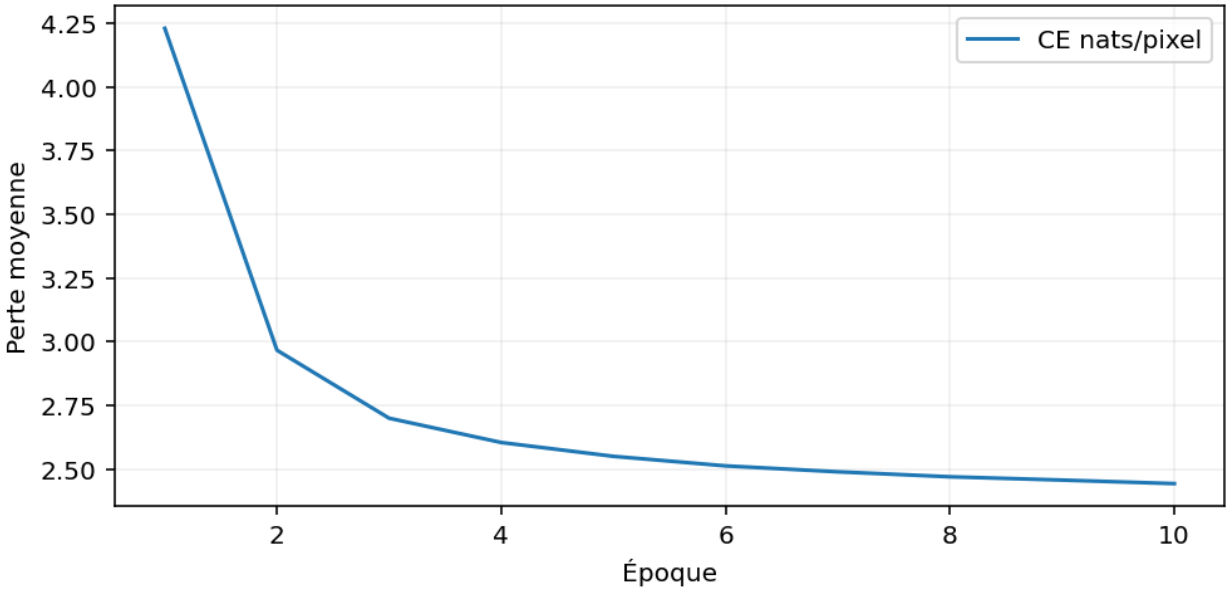


Cette grille permet de comparer qualitativement le respect de la classe et la diversité. Aucun score de conformité par un classifieur indépendant n'a été calculé : une précision numérique ne serait donc pas justifiée.

Respecter l’ordre causal des pixels

La couche A, noyau 7, exclut le pixel courant et tous les futurs pixels. Trois couches B, noyau 3, exploitent des représentations déjà causales. La sortie comporte 256 logits par pixel et s’entraîne par entropie croisée.

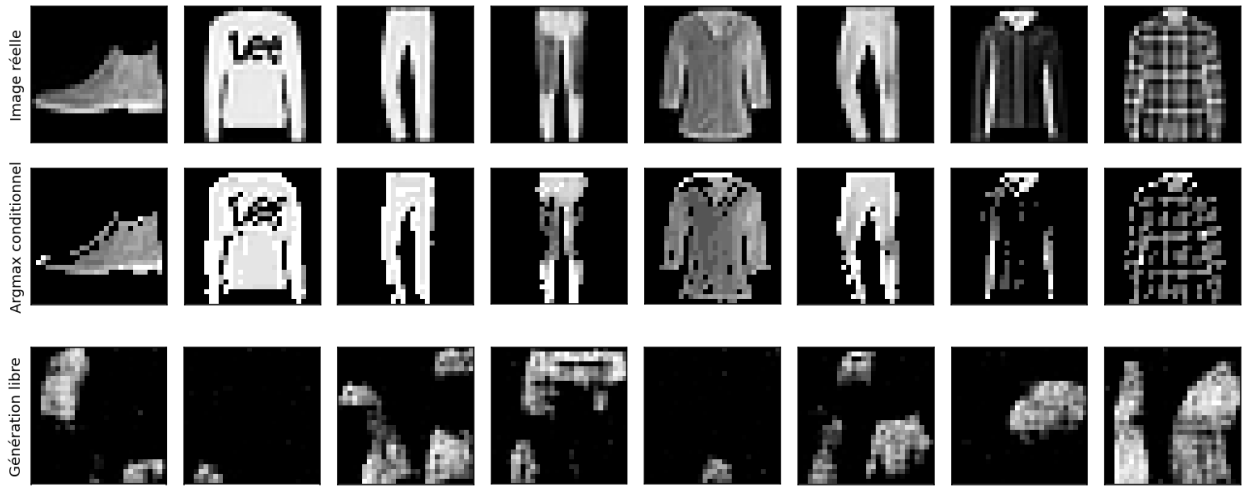




Test de causalité : changement des pixels courant et futurs, différence maximale des logits courants = 0. Le test numérique passe ; la construction des masques explique pourquoi.

10 / PIXELCNN : RÉSULTATS

Prédiction conditionnelle et génération libre



La première comparaison utilise le contexte réel des images test : elle n'est pas une génération libre. La seconde grille part d'images vides et tire successivement les 784 pixels ; chaque pixel tiré devient le contexte du suivant.

Test : 2.4486 nats/pixel, soit 3.5326 bits/pixel. Génération de 8 images : 1.9 secondes. Les générations libres sont fragmentaires et ne représentent pas des vêtements cohérents de façon fiable. Le modèle compact et le sous-ensemble d'apprentissage limitent la qualité des échantillons.

11 / QUESTIONS DE RÉFLEXION

Expliquer les douze idées essentielles

Réponses A

1. La compression retient des structures fréquentes des vêtements ; une petite perturbation peut être rejetée lors de la reconstruction. Ce comportement n'est pas garanti : un bruit trop fort détruit de l'information. Le DAE apprend ce rejet.

2. Les convolutions exploitent le voisinage des pixels et partagent les filtres. Cela convient aux images, sans garantir une meilleure MSE pour tout entraînement.

3. L'AE classique n'impose aucune distribution aux codes. Un segment entre deux codes peut donc traverser une zone jamais rencontrée pendant l'apprentissage.

Réponses B

1. La KL empêche les distributions encodées de s'éloigner librement de N(0,I). L'espace est ainsi mieux adapté au tirage de nouveaux codes que celui d'un AE.

2. Une KL trop forte réduit l'information disponible pour reconstruire ; une KL trop faible laisse des régions du prior difficiles à décoder. C'est un compromis.

3. La vraisemblance pixel par pixel et la compression peuvent produire des sorties moyennes, donc floues, lorsque plusieurs détails sont plausibles. β est fixé à

1. L'étude optionnelle de plusieurs β n'est pas réalisée ; aucune comparaison expérimentale entre β n'est donc revendiquée.

Réponses C

1. Le CVAE fournit une variable explicite y pour choisir la classe ; le VAE standard ne possède pas ce bouton de contrôle.

2. Si y est absent ou ignoré, le modèle peut mélanger les classes et ne pas suivre la consigne. L'injection dans les deux réseaux favorise un apprentissage cohérent.

3. Non : il faut aussi tester la conformité à y et la diversité. Ici la grille permet une inspection qualitative ; elle ne constitue pas une précision mesurée.

Réponses D

1. Le masque A interdit de voir le pixel à prédire. Les couches B ne manipulent que des caractéristiques déjà causales ; les pixels futurs restent inaccessibles.

2. Le pixel suivant dépend de ceux déjà tirés. L'entraînement prédit toutes les positions en parallèle grâce aux masques ; la génération reste séquentielle.

3. PixelCNN optimise directement une vraisemblance discrète, sans encodeur latent ni KL. Son échantillonnage est coûteux. Un VAE génère toute l'image en une passe, offre un espace latent manipulable, mais optimise une borne et peut lisser les détails.

12 / BILAN

Ce que chaque famille permet de faire

Famille	But	Limite principale
AE	Reconstruire / compresser	Prior latent non imposé
DAE	Retrouver une image propre	Information perdue par le bruit
VAE	Générer depuis un prior	Fidélité contre régularisation
CVAE	Générer selon une classe	Respect de la condition à vérifier
PixelCNN	Vraisemblance causale	Génération séquentielle coûteuse

MSE, BCE + KL et entropie croisée ne mesurent pas la même quantité et ne se comparent pas directement. La fidélité d'une reconstruction, la qualité d'une génération et la conformité à une classe sont trois objectifs différents.

Le notebook contient les courbes, les sorties et les explications avant chaque bloc de code. Les fichiers de poids permettent de recharger les six modèles. Les jeux officiels sont téléchargés automatiquement par torchvision ; ils sont conservés localement mais exclus du ZIP pour éviter une archive inutilement volumineuse.

Vérifications : toutes les cellules de code sont exécutées sans erreur ; pertes finies ; dimensions de reconstruction contrôlées ; six fichiers de poids présents ; test causalité PixelCNN passé. Les qualités visuelles sont laissées visibles dans les figures et ne sont pas remplacées par des affirmations de performance.